KI PRAXIS

Die Handbuchreihe für produktives Arbeiten mit künstlicher Intelligenz

BAND 5

Datenanalyse mit KI

Daten verstehen, auswerten und visualisieren

Eugen Becker

1. Auflage, November 2026

Impressum und Nutzungshinweise

Reihe KI PRAXIS, Band 5: Datenanalyse mit KI. Daten verstehen, auswerten und visualisieren.

Herausgeber und Autor: Eugen Becker.

1. Auflage, November 2026. Alle Rechte vorbehalten. Das Werk einschließlich aller Teile ist urheberrechtlich geschützt. Jede Verwertung außerhalb der engen Grenzen des Urheberrechtsgesetzes bedarf der Zustimmung des Herausgebers.

Hinweis zu den Beispieldaten und Codebeispielen: Alle Daten in diesem Band sind frei erfunden und dienen nur zur Übung. Die Programme wurden mit Python 3.12 und Pandas 3.0 ausgeführt, die Ausgaben im Buch stammen aus diesen Läufen. Ältere oder neuere Versionen von Pandas und Matplotlib können Ausgaben in Einzelheiten verändern.

Formeln für Tabellenkalkulationen sind in diesem Band beschrieben, aber nicht in einem Tabellenprogramm ausgeführt worden. Prüfe sie an einer Stichprobe, bevor du sie verwendest.

Angaben zu Programmen und Oberflächen sind versionsabhängig. Prüfe vor dem Einsatz die aktuelle Dokumentation des jeweiligen Anbieters oder Projekts.

Gesetze und Richtlinien werden in dem Stand zitiert, der zum Zeitpunkt der Drucklegung galt. Maßgeblich ist immer die aktuell gültige Fassung.

Vorwort

Zahlen wirken objektiv. Eine Tabelle sieht ordentlich aus, ein Diagramm überzeugt, und eine Kennzahl fasst viel Arbeit in einen Wert zusammen. Gerade deshalb gehören Datenanalysen zu den Bereichen, in denen Fehler am folgenreichsten und am schwersten zu erkennen sind. Dieser Band hilft dir, die Analyse so zu gestalten, dass sie einer Prüfung standhält.

Sprachmodelle können beim Auswerten helfen. Sie schreiben Formeln, erklären Auswertungen und schlagen Diagrammtypen vor. Sie können aber auch Formeln liefern, die falsch rechnen, und Zusammenhänge behaupten, die in den Daten nicht stecken. Der Band zeigt, wie du beides erkennst.

Die Beispiele arbeiten mit einem fiktiven Verkaufsdatensatz, den du im Anhang-Archiv findest. Er enthält absichtlich typische Fehler. Die Übung besteht darin, sie zu finden, bevor du rechnest. Vorausgesetzt werden die Grundlagen aus Band 1 und die Prüfregeln aus Band 2.

Einleitung und Zielgruppe

Dieser Band richtet sich an Menschen, die Tabellen auswerten, Berichte erstellen oder Entscheidungen auf Zahlen stützen. Dazu gehören Fachkräfte in Verwaltung, Vertrieb und Controlling ebenso wie Studierende und alle, die mit eigenen Daten arbeiten.

Die Kapitel 1 bis 3 setzen nur Kenntnisse im Tabellenprogramm voraus. Die Kapitel 4 bis 6 verwenden Python und SQL. Dafür brauchst du keine Vorkenntnisse in der Programmierung, aber die Bereitschaft, Programmzeilen Schritt für Schritt nachzuvollziehen. Die Kapitel 7 und 8 verbinden alles und verlangen sorgfältiges Denken über Aussagekraft.

Die Hinweisboxen kehren zurück. Achtung-Kästen markieren Stellen, an denen Analysen typischerweise in die Irre führen, etwa bei fehlenden Werten, Korrelationen und Prognosen.

Lernziele

- Du prüfst einen Datensatz systematisch auf Dubletten, fehlende Werte, Formatfehler und unplausible Werte.
- Du bereitest Daten so auf, dass jede Entscheidung über Fehler nachvollziehbar dokumentiert ist.
- Du erstellst Pivot-Auswertungen und prüfst Formeln, die eine KI vorschlägt.
- Du führst Auswertungen mit Pandas durch und verstehst, was die einzelnen Schritte bewirken.
- Du formulierst Abfragen in SQL und prüfst sie gegen eine unabhängige Rechnung.

- Du wählst Diagrammtypen passend zur Fragestellung und erstellst eine Grafik mit Matplotlib.
- Du erkennst Trends, Ausreißer und Zusammenhänge und kennst die Grenzen statistischer Aussagen.

Inhaltsverzeichnis

Kapitel 1: Grundlagen der Datenanalyse 9

1.1 Was ist Datenanalyse? . . . 9

1.2 Datenarten . . . 9

1.3 Datenqualität . . . 10

1.4 Datenaufbereitung . . . 11

Kapitel 2: Tabellen und Datenquellen 14

2.1 Excel . . . 14

2.2 CSV . . . 14

2.3 JSON . . . 15

2.4 Datenbanken . . . 15

2.5 Import und Export . . . 15

Kapitel 3: KI und Excel 17

3.1 Formeln erstellen . . . 17

3.2 Tabellen analysieren . . . 18

3.3 Pivot-Tabellen . . . 18

3.4 Fehler finden . . . 20

3.5 Auswertungen automatisieren . . . 20

Kapitel 4: Python für Datenanalyse 22

4.1 Python-Grundlagen . . . 22

4.2 Pandas: Lesen, Filtern, Berechnen . . . 22

4.3 Datenbereinigung 22
4.4 NumPy 24
4.5 Statistische Auswertungen 24

Kapitel 5: SQL und KI **26**

5.1 SQL-Grundlagen 26
5.2 SELECT und JOIN 26
5.3 GROUP BY 26
5.4 Abfragen mit KI erstellen 26
5.5 Abfragen überprüfen und optimieren 27

Kapitel 6: Datenvisualisierung **31**

6.1 Diagrammtypen 31
6.2 Gestaltung und Lesbarkeit 31
6.3 Matplotlib 31
6.4 Interaktive Visualisierungen 33
6.5 Dashboards 33
6.6 Daten verständlich präsentieren 33

Kapitel 7: KI-gestützte Interpretation **35**

7.1 Trends erkennen 35
7.2 Auffälligkeiten erkennen 35
7.3 Kennzahlen interpretieren 35
7.4 Prognosen und Szenarien 36
7.5 Grenzen statistischer Aussagen 36
7.6 Ein Ergebnis kritisch bewerten 38

Kapitel 8: Praxisprojekte **40**

8.1 Hinweise zu den Projekten 40

8.2 Projekt 1: Verkaufsdaten analysieren 40

8.3 Projekt 2: Datenqualitätsbericht für eine eigene Tabelle 41

8.4 Projekt 3: Monatsbericht mit Prüfung 42

Musterlösungen **44**

Anhang: Checkliste für eine Datenanalyse **47**

Glossar **48**

Quellenverzeichnis **50**

Stichwortverzeichnis **51**

Kapitel 1: Grundlagen der Datenanalyse

1.1 Was ist Datenanalyse?

Datenanalyse ist der Weg von einer Sammlung von Werten zu einer begründeten Antwort auf eine Frage. Die Frage kommt zuerst. Wer wissen will, ob eine Maßnahme den Umsatz gesteigert hat, braucht andere Daten und andere Auswertungen als jemand, der nur den Umsatz des letzten Quartals sehen möchte. Ohne Frage wird jede Auswertung beliebig, weil sich zu fast jedem Datensatz viele Zahlen berechnen lassen.

Eine saubere Analyse folgt meist fünf Schritten: Frage formulieren, Daten beschaffen, Daten prüfen und aufbereiten, auswerten und interpretieren, Ergebnis dokumentieren. Die Schritte wiederholen sich oft, denn die Auswertung wirft neue Fragen auf, die weitere Daten verlangen. Dieser Band folgt dieser Reihenfolge und beginnt bei der Prüfung, weil sie am häufigsten vernachlässigt wird.

1.2 Datenarten

Daten lassen sich grob in zwei Gruppen teilen. Kategoriale Daten beschreiben eine Zugehörigkeit, etwa eine Region, ein Produkt oder eine Kundengruppe. Numerische Daten sind Zahlen, mit denen man rechnen kann, etwa Menge, Preis oder Dauer. Diese Unterscheidung bestimmt, welche Auswertung sinnvoll ist. Einen Durchschnitt der Regionen ergibt keinen Sinn, eine Summe der Mengen dagegen schon.

Daten haben außerdem einen Zeitbezug. Zeitreihen, also Werte in einer festen Abfolge, zeigen Entwicklungen, verlangen aber besondere Vorsicht bei Vergleichen. Eine Zahl aus dem Dezember ist mit einer aus dem Februar nur dann vergleichbar, wenn man die Saison

berücksichtigt.

1.3 Datenqualität

Datenqualität beschreibt, wie gut ein Datensatz für eine bestimmte Frage geeignet ist. Dazu zählen Vollständigkeit, also ob alle nötigen Werte vorhanden sind, Eindeutigkeit, also ob jede Zeile nur einmal vorkommt, Gültigkeit, also ob Werte im erlaubten Bereich liegen, und Einheitlichkeit, also ob gleiche Dinge gleich geschrieben sind. Ein Datensatz kann in einem Punkt gut und im anderen schlecht sein.

Typische Probleme sind Dubletten durch doppelten Export, unterschiedliche Schreibweisen wie Nord und nord, Datumsangaben in verschiedenen Formaten und Negativwerte, die eine Stornierung bedeuten können. Viele dieser Fehler sind für das Auge unauffällig, deshalb braucht es eine systematische Prüfung.

Codebeispiel 1.1: Qualitätsprüfung eines Verkaufsdatensatzes

```
import pandas as pd

df = pd.read_csv("verkauf.csv", sep=";", dtype=str)
print("Zeilen:", len(df))
print("Vollstaendige Dubletten:", df.duplicated().sum())
print("Doppelte Bestell-IDs:", df["bestell_id"].duplicated().sum())
print("Fehlende Werte je Spalte:")
print(df.isna().sum().to_string())
print("Leere Preise:", (df["einzelpreis"].fillna("") == "").sum())
print("Regionen (roh):", sorted(df["region"].unique()))
print("Produkte (roh):", sorted(df["produkt"].unique()))

datum = pd.to_datetime(df["datum"], format="%Y-%m-%d", errors="coerce")
print("Datum nicht im Format JJJJ-MM-TT:", datum.isna().sum())
fehler = df.loc[datum.isna(), ["bestell_id", "datum"]]
print(fehler.to_string(index=False))

menge = pd.to_numeric(df["menge"], errors="coerce")
print("Negative Mengen:", (menge < 0).sum())
negativ = df.loc[menge < 0, ["bestell_id", "menge"]]
print(negativ.to_string(index=False))
```

Ausgabe

```
Zeilen: 1096
Vollstaendige Dubletten: 1
Doppelte Bestell-IDs: 1
Fehlende Werte je Spalte:
bestell_id     0
datum          0
region         0
produkt        0
menge          0
einzelpreis    2
Leere Preise: 2
Regionen (roh): ['Nord', 'Ost', 'Sued', 'Süd', 'West', 'nord ']
Produkte (roh): ['A', 'B', 'C', 'b']
Datum nicht im Format JJJJ-MM-TT: 1
bestell_id      datum
      1201 03.06.2025
Negative Mengen: 1
bestell_id menge
      1121    -2
```

Das Skript liest die Datei als Text ein, damit Pandas keine Werte stillschweigend umwandelt. Die Ausgabe zeigt die Befunde. Eine Dublette wurde gefunden, und zwar eine vollständige Zeilendublette. Außerdem gibt es eine doppelte Bestell-Nummer. Zwei Preise fehlen. Die Regionen sind in sechs Schreibweisen vorhanden, obwohl es vier Regionen gibt. Ein Datum liegt nicht im erwarteten Format, und eine Menge ist negativ. Jeder dieser Befunde verlangt eine Entscheidung, die im nächsten Abschnitt folgt.

1.4 Datenaufbereitung

Aufbereitung heißt, aus den rohen Daten einen Datensatz zu machen, der für die Frage taugt. Dabei werden Fehler behoben, Werte vereinheitlicht und neue Spalten berechnet. Jede dieser Änderungen ist eine Entscheidung, und jede Entscheidung gehört dokumentiert. Eine Dublette zu löschen ist unkritisch, wenn sie nachweislich doppelt ist. Eine negative Menge zu löschen kann dagegen die Zahlen verfälschen, denn sie gehört möglicherweise zu einem Storno.

Als Faustregel gilt: Lösche nichts ohne Begründung, markiere lieber. Eine Spalte, die Stornos kennzeichnet, lässt sich später jederzeit auswerten oder ausschließen. Ein gelöschter Datensatz kommt nicht zurück. Das Beispiel in Kapitel 4 zeigt diese Schritte im Detail.

Schritt für Schritt: Entscheidungen bei der Aufbereitung festhalten

1. Liste jeden Befund aus der Prüfung auf, mit Anzahl und Beispiel.
2. Notiere für jeden Befund die Entscheidung: korrigieren, ergänzen, markieren oder ausschließen.
3. Begründe jede Entscheidung in einem Satz, mit Bezug auf die Frage.
4. Halte die Regeln in einem Protokoll fest, das zusammen mit den Daten abgelegt wird.
5. Prüfe nach der Aufbereitung dieselben Befunde erneut und dokumentiere das Ergebnis.

Erwartetes Ergebnis: Ein Protokoll, das jede Änderung am Datensatz nachvollziehbar macht und nach der Aufbereitung keine offenen Befunde mehr enthält.

Typische Fehler

Der häufigste Fehler ist, die Prüfung zu überspringen und direkt zu rechnen. Ein zweiter ist, fehlende Werte mit dem Durchschnitt zu füllen, ohne zu prüfen, ob das die Auswertung verzerrt. Ein dritter ist, Ausreißer ohne Nachfrage zu entfernen, obwohl sie echte Ereignisse abbilden, etwa einen Großauftrag.

Kurz gesagt

Analyse beginnt mit einer Frage und einer systematischen Prüfung der Daten. Jede Änderung ist eine Entscheidung und gehört dokumentiert. Löschen ist die letzte Option, nicht die erste.

Übungen

Übung 1.1: Prüfe die Datei verkauf.csv von Hand an den ersten fünfzig Zeilen. Notiere, was dir auffällt, bevor du das Skript ausführst.

Übung 1.2: Nenne für eine Datenquelle aus deinem Alltag drei Qualitätsprobleme, die dort typischerweise auftreten, und eine Prüfung für jedes.

Kapitel 2: Tabellen und Datenquellen

2.1 Excel

Excel ist das verbreitetste Werkzeug für Tabellen. Es verbindet Speicherung, Berechnung und Darstellung in einer Oberfläche. Seine Stärke liegt in der direkten Sichtbarkeit: Jede Zelle zeigt ihren Wert, und Formeln lassen sich nachvollziehen. Seine Schwäche liegt in der Größe und in der Nachvollziehbarkeit. Bei mehreren zehntausend Zeilen wird es langsam, und Änderungen an Formeln bleiben oft unbemerkt.

Ein wichtiger Grundsatz lautet, Rohdaten getrennt von Auswertungen zu halten. Die Rohdaten stehen in einem Blatt, unverändert. Die Auswertung liegt in einem anderen Blatt und verweist auf die Rohdaten. So bleibt nachvollziehbar, woher jede Zahl stammt.

2.2 CSV

Eine CSV-Datei ist eine Textdatei, in der Zeilen Datensätze und Trennzeichen die Felder bilden. Das Trennzeichen ist nicht genormt. In deutschsprachigen Exporten findest du oft das Semikolon, weil das Komma als Dezimaltrennzeichen dient. Beim Einlesen musst du das Trennzeichen angeben, sonst entstehen falsche Spalten. Ebenso wichtig ist die Zeichenkodierung, meist UTF-8, damit Umlaute richtig erscheinen.

2.3 JSON

JSON eignet sich für verschachtelte Daten, wie sie Programme und Schnittstellen liefern. Ein Datensatz kann Listen und Unterobjekte enthalten, die sich in einer Tabelle nur mit Mühe abbilden lassen. Für die Analyse werden solche Daten meist in eine flache Tabelle überführt. Dabei gehen Verschachtelungen verloren, die man bewusst prüfen sollte.

2.4 Datenbanken

Datenbanken speichern Daten in Tabellen, die über gemeinsame Schlüssel verbunden sind. Eine Kundentabelle und eine Bestelltabelle lassen sich über die Kundennummer verknüpfen, ohne dass Kundendaten in jeder Bestellung wiederholt werden. Dieses Prinzip heißt relationales Modell, das Edgar F. Codd 1970 beschrieben hat. Abschnitt 5 behandelt die Abfragesprache SQL, mit der man diese Tabellen auswertet.

2.5 Import und Export

Beim Import entscheiden Trennzeichen, Kodierung, Datentypen und der Umgang mit Datumsangaben über die Qualität des Ergebnisses. Ein Datum mit Tag zuerst, etwa 03.06.2025, wird ohne Angabe des Formats als 6. März gelesen. Lege deshalb das Format fest, statt es dem Programm zu überlassen.

Beim Export gilt dieselbe Sorgfalt. Ein Export aus Excel als CSV verliert Formatierungen und kann Dezimalstellen anders darstellen. Teste jeden Export, indem du die Datei erneut einliest und die Summen vergleichst.

Achtung: Datenschutz bei Exporten

Exporte aus Kundensystemen enthalten oft Namen, Adressen und Kontaktdaten, auch wenn du sie nicht brauchst. Entferne alle Spalten, die für die Frage nicht nötig sind, bevor du eine Datei weitergibst oder in ein externes Werkzeug lädst.

Typische Fehler

Der häufigste Fehler beim Import ist ein falsches Trennzeichen oder Dezimalzeichen, das zu Zahlen führt, die plötzlich tausendmal größer oder kleiner sind. Ein zweiter ist, Excel zu erlauben, Zahlen beim Öffnen zu verändern, etwa führende Nullen bei Postleitzahlen zu entfernen.

Kurz gesagt

Die Datenquelle bestimmt die Ausgangsqualität. Trennzeichen, Kodierung und Datumsformat gehören bei jedem Import geprüft, und Exporte werden durch erneutes Einlesen kontrolliert.

Übungen

Übung 2.1: Lies die Datei verkauf.csv ein, einmal mit dem richtigen und einmal mit einem falschen Trennzeichen. Beschreibe den Unterschied.

Übung 2.2: Nenne für eine Datei aus deinem Alltag, welche Spalten du für deine Frage brauchst und welche du vor einer Weitergabe entfernen würdest.

Kapitel 3: KI und Excel

3.1 Formeln erstellen

Sprachmodelle schreiben häufig brauchbare Formeln für Tabellenprogramme, besonders wenn du das gewünschte Ergebnis genau beschreibst. Eine gute Anfrage nennt die Spalten, ihren Datentyp, die Bedingung und das gewünschte Ergebnis. Ein Beispiel: „In Spalte D steht der Umsatz, in Spalte C die Region. Berechne die Summe des Umsatzes für die Region in Zelle F2.“ Die Antwort enthält dann eine Formel, die du an einer bekannten Summe prüfen kannst.

Die Namen von Funktionen unterscheiden sich je nach Sprache der Oberfläche. Im deutschen Excel heißt die Funktion für Summen mit Bedingungen SUMMEWENNS, im englischen SUMIFS. Achte darauf, dass die Formel in der Sprache deines Programms steht, und dass die Trennzeichen zwischen den Argumenten zu deinen Einstellungen passen.

Beispiel: Formel mit eindeutiger Beschreibung

```
Ich habe eine Tabelle mit den Spalten A bis F. Spalte C
enthält die Region, Spalte D den Umsatz in Euro und Spalte
E das Datum. Schreibe eine Formel für Zelle H2, die den
Umsatz der Region aus Zelle G2 für das Jahr 2025 summiert.
Nenne die Funktion in deutscher Excel-Schreibweise und
erkläre in einem Satz, wie die Formel funktioniert.
```

3.2 Tabellen analysieren

Ein Modell kann auch eine ganze Tabelle sichten und Auffälligkeiten nennen, etwa fehlende Werte, ungewöhnlich hohe Beträge oder doppelte Einträge. Diese Hinweise sind wertvoll, aber sie sind Hypothesen. Prüfe jeden Hinweis an den Originaldaten, bevor du etwas änderst.

3.3 Pivot-Tabellen

Eine Pivot-Tabelle fasst Daten nach Zeilen und Spalten zusammen. Sie ist das wichtigste Werkzeug für Auswertungen mit Gruppierungen, etwa Umsatz je Region und Quartal. Die Logik lässt sich in drei Fragen zerlegen: Welche Werte soll ich summieren oder zählen? Nach welchen Merkmalen gruppiere ich die Zeilen? Nach welchen Merkmalen gruppiere ich die Spalten?

Das folgende Beispiel erzeugt eine Pivot-Tabelle mit Pandas und exportiert die Ergebnisse nach Excel. Die Pivot-Tabelle entspricht dem, was du im Tabellenprogramm über den Menüpunkt für Pivot-Tabellen erzeugst. Der Vorteil der Programmfassung ist, dass sie sich bei neuen Daten mit einem Klick wiederholen lässt.

Codebeispiel 3.1: Pivot-Tabelle und Excel-Export

```
import pandas as pd

df = pd.read_csv("verkauf_bereinigt.csv", sep=";", parse_dates=["datum"])
df = df[~df["storno"]]

# Pivot-Tabelle: Umsatz je Region und Quartal
df["quartal"] = df["datum"].dt.to_period("Q").astype(str)
pivot = pd.pivot_table(df, values="umsatz", index="region",
                       columns="quartal", aggfunc="sum",
                       margins=True, margins_name="Summe")
print(pivot.round(0).to_string())

# Excel-Datei mit zwei Blaettern, Ergebnis wird in der Tabelle erkennbar
with pd.ExcelWriter("auswertung.xlsx", engine="openpyxl") as writer:
    df.to_excel(writer, sheet_name="Daten", index=False)
    pivot.round(2).to_excel(writer, sheet_name="Pivot")
print("Excel geschrieben")
```

Ausgabe

```
quartal   2025Q1   2025Q2   2025Q3   2025Q4     Summe
region
Nord      8791.0   9283.0   8152.0  10426.0   36653.0
Ost       9871.0   9340.0  10200.0  13887.0   43298.0
Süd       8938.0   9296.0  10169.0  15005.0   43408.0
West      8514.0  11106.0  12582.0  12329.0   44531.0
Summe    36115.0  39026.0  41102.0  51647.0  167890.0
Excel geschrieben
```

Das Skript entfernt die Stornos, bevor es summiert, und zeigt die Summe am Ende jeder Zeile und Spalte. Die Summe ist 167.890 Euro, die Zusammenfassung der Quartale stimmt damit überein. Die Gesamtsumme aus dem Bereinigungsskript in Kapitel 4 liegt um rund 98 Euro niedriger, weil dort die Storno-Zeile mitgezählt wird. Die Pivot-Tabelle schließt sie aus. Die Excel-Datei enthält die Rohdaten und die Pivot-Tabelle in getrennten Blättern.

3.4 Fehler finden

Die häufigsten Fehler in Tabellenformeln sind falsche Bereiche, fehlende Absolutbezüge beim Kopieren und Summen, die Text enthalten. Eine Formel rechnet fehlerfrei, wenn sie das Falsche berechnet. Deshalb prüft man sie mit einer unabhängigen Rechnung. Summiere die Werte von Hand für eine Stichprobe, oder vergleiche das Ergebnis mit einer Pivot-Tabelle.

Schritt für Schritt: Eine KI-Formel prüfen

1. Lies die Formel und übersetze sie in einen Satz, der die Bedingung und den Bereich nennt.
2. Wähle eine Stichprobe von drei bis fünf Zeilen und berechne das Ergebnis von Hand.
3. Vergleiche das Ergebnis der Formel mit der Stichprobe.
4. Prüfe den Bereich auf Anfang, Ende und vollständige Abdeckung der Daten.
5. Dokumentiere die geprüfte Formel zusammen mit dem Prüfergebnis.

Erwartetes Ergebnis: Eine Formel, deren Ergebnis an einer unabhängigen Rechnung gemessen ist und deren Bereich geprüft wurde.

3.5 Auswertungen automatisieren

Wiederkehrende Auswertungen lassen sich mit einem Skript oder mit einer Makrofunktion des Tabellenprogramms automatisieren. Makros sind bequem, aber schwer zu prüfen und bergen Sicherheitsrisiken, wenn sie aus unbekannten Quellen stammen. Ein Skript in Python ist transparenter, verlangt aber Grundkenntnisse. Beide Wege verlangen eine Prüfung nach jeder Änderung der Eingabedaten.

Achtung: Makros aus unbekannten Quellen

Makros können beliebige Befehle ausführen. Öffne Dateien mit Makros nur, wenn du die Herkunft kennst, und aktiviere Makros nicht pauschal. Ein Modell kann Makros schreiben, aber dessen Code muss vor der Verwendung gelesen werden.

Typische Fehler

Der häufigste Fehler ist, eine Formel zu übernehmen, die plausibel aussieht, und sie nie an einer Stichprobe zu prüfen. Ein zweiter ist, eine Pivot-Tabelle auf Daten zu erstellen, die nicht aktualisiert wurden, und mit veralteten Zahlen zu arbeiten.

Kurz gesagt

KI kann Formeln schreiben und Auffälligkeiten nennen. Jede Formel braucht eine Prüfung an einer unabhängigen Rechnung, und jede Auswertung braucht den richtigen Datenstand.

Übungen

Übung 3.1: Lass eine Formel für eine Summe mit Bedingung erstellen und prüfe sie an drei Zeilen von Hand.

Übung 3.2: Erstelle mit dem Skript eine Pivot-Tabelle, die den Umsatz je Produkt und Monat zeigt. Welche Zelle prüfst du zuerst, und warum?

Kapitel 4: Python für Datenanalyse

4.1 Python-Grundlagen

Python ist eine Programmiersprache, die für Datenanalyse weit verbreitet ist, weil sie gut lesbar ist und umfangreiche Bibliotheken bietet. Für die Arbeit mit Tabellen braucht man vor allem die Bibliothek Pandas. Sie stellt eine Tabellenstruktur bereit, den DataFrame, mit Spalten, Zeilen und Funktionen zum Filtern, Gruppieren und Verbinden.

Die Beispiele dieses Kapitels setzen Pandas in der Version 3.0 voraus. Die Schreibweisen ändern sich zwischen Versionen, deshalb ist die Angabe der Version wichtig. Mit einem Befehl im Terminal lässt sich die installierte Version prüfen, und in einer virtuellen Umgebung lässt sich eine feste Version halten.

4.2 Pandas: Lesen, Filtern, Berechnen

Pandas liest Dateien mit einer Funktion ein, die Trennzeichen und Datentypen als Angaben nimmt. Eine Spalte wählt man über ihren Namen aus. Zeilen filtert man über eine Bedingung in eckigen Klammern, die eine Liste von Wahr und Falsch liefert. Neue Spalten entstehen durch einfache Rechnungen auf ganzen Spalten, ohne Schleifen. Dieser Ansatz heißt vektorisiert und ist schneller und lesbarer als eine Zeile-für-Zeile-Schleife.

4.3 Datenbereinigung

Das folgende Skript führt die Schritte aus Kapitel 1 aus. Jeder Schritt ist mit einem Kommentar benannt, damit du die Entscheidung findest, die du gegebenenfalls ändern möchtest. Das Ergebnis wird in eine neue Datei geschrieben, die Rohdaten bleiben unverändert.

Codebeispiel 4.1: Datenbereinigung mit Pandas

```
import pandas as pd

df = pd.read_csv("verkauf.csv", sep=";", dtype=str)
n_roh = len(df)

# 1. Vollstaendige Dubletten entfernen
df = df.drop_duplicates()

# 2. Regionen vereinheitlichen
ersetzung = {"nord": "Nord", "sued": "Süd", "süd": "Süd",
             "west": "West", "ost": "Ost"}
df["region"] = df["region"].str.strip().str.lower().map(ersetzung)

# 3. Produktcodes vereinheitlichen
df["produkt"] = df["produkt"].str.strip().str.upper()

# 4. Datum in ein einheitliches Format bringen
iso = pd.to_datetime(df["datum"], format="%Y-%m-%d", errors="coerce")
tag_zuerst = pd.to_datetime(df["datum"], format="%d.%m.%Y",
                            errors="coerce")
df["datum"] = iso.fillna(tag_zuerst)

# 5. Zahlen umwandeln
df["menge"] = pd.to_numeric(df["menge"])
df["einzelpreis"] = pd.to_numeric(df["einzelpreis"])

# 6. Fehlende Preise aus der Preisliste ergaenzen
preise = (df.dropna(subset=["einzelpreis"])
            .groupby("produkt")["einzelpreis"].first())
df["einzelpreis"] = df["einzelpreis"].fillna(df["produkt"].map(preise))

# 7. Stornos nicht loeschen, sondern markieren
df["storno"] = df["menge"] < 0
df["umsatz"] = df["menge"] * df["einzelpreis"]
df["monat"] = df["datum"].dt.to_period("M").astype(str)

print("Zeilen vorher:", n_roh, "nachher:", len(df))
print("Stornos:", df["storno"].sum())
print("Gesamtumsatz:", round(df["umsatz"].sum(), 2))
df.to_csv("verkauf_bereinigt.csv", index=False, sep=";")
```

Ausgabe

```
Zeilen vorher: 1096 nachher: 1095
Stornos: 1
Gesamtumsatz: 167791.5
```

Die Ausgabe zeigt, dass eine Zeile gelöscht wurde, weil sie vollständig doppelt war. Eine Storno-Zeile wurde markiert und nicht gelöscht. Der Gesamtumsatz schließt die Storno-Zeile ein, weil sie negativ ist. Zwei fehlende Preise wurden aus der Preisliste ergänzt, und zwar aus dem Preis desselben Produkts. Das ist eine Annahme: Sie gilt nur, wenn der Preis im Datensatz konstant ist. Eine Prüfung des Preisverlaufs wäre der nächste Schritt.

Achtung: Fehlende Werte nicht stillschweigend füllen

Eine Ergänzung fehlender Werte ist eine Annahme über die Realität. Ein fehlender Preis aus der Preisliste ist plausibel, eine fehlende Menge ist es nicht. Dokumentiere jede Ergänzung und prüfe, ob sie die Auswertung verändert.

4.4 NumPy

NumPy ist die Bibliothek für numerische Berechnungen mit Feldern von Zahlen. Pandas baut darauf auf. Für Auswertungen wie Durchschnitte, Standardabweichungen oder Anpassung einer Geraden stellt NumPy schnelle Funktionen bereit. Im Kapitel 7 wird eine Geradenanpassung gezeigt, die auf NumPy beruht.

4.5 Statistische Auswertungen

Bevor du eine Kennzahl berechnest, prüfe ihre Verteilung. Der Mittelwert ist empfindlich gegenüber einzelnen großen Werten, der Median nicht. Eine Gruppierung mit wenigen Beobachtungen liefert instabile Mittelwerte. Diese Überlegungen gehören zur Grundlage jeder Auswertung, nicht zur Statistik allein.

Typische Fehler

Ein häufiger Fehler ist, Spalten mit Zahlen als Text einzulesen, sodass Summen unmöglich oder falsch sind. Ein zweiter ist, eine Zeile-für-Zeile-Schleife zu schreiben, obwohl eine vektorisierte Lösung einfacher ist. Ein dritter ist, Änderungen direkt in den Rohdaten vorzunehmen und das Original zu verlieren.

Kurz gesagt

Pandas macht Tabellen mit wenigen Zeilen Code auswertbar. Jede Bereinigung wird als eigener, benannter Schritt geschrieben und an den Rohdaten gemessen.

Übungen

Übung 4.1: Ändere das Skript so, dass Stornos ausgeschlossen statt markiert werden. Welche Summe ergibt sich?

Übung 4.2: Ergänze das Skript um eine Prüfung, die alle Produkte ohne Preis in einer Liste ausgibt, bevor sie ergänzt werden.

Kapitel 5: SQL und KI

5.1 SQL-Grundlagen

SQL, die Structured Query Language, ist die Sprache für Abfragen an relationale Datenbanken. Eine Abfrage beschreibt, welche Daten du willst, und die Datenbank entscheidet, wie sie diese findet. Das Grundgerüst ist immer dasselbe: Eine Auswahl von Spalten, eine Quelltabelle, optional Bedingungen, Gruppierungen und Sortierung.

5.2 SELECT und JOIN

Mit SELECT wählst du Spalten aus einer Tabelle. Mit JOIN verbindest du zwei Tabellen über eine gemeinsame Spalte. Ein JOIN ist eine der häufigsten Fehlerquellen, weil er die Zeilen vervielfachen kann. Wenn eine Seite des JOIN denselben Schlüssel mehrfach enthält, erscheinen die Zeilen der anderen Seite mehrfach. Jede Summe nach einem solchen JOIN ist dann zu hoch.

5.3 GROUP BY

GROUP BY fasst Zeilen mit gleichem Wert in einer Spalte zusammen, damit Funktionen wie SUM und COUNT pro Gruppe rechnen. Jede Spalte, die im SELECT steht und keine Aggregatfunktion ist, muss im GROUP BY erscheinen. Vergisst man das, lehnt die Datenbank die Abfrage ab, oder sie liefert, je nach System, ein unerwartetes Ergebnis.

5.4 Abfragen mit KI erstellen

Ein Sprachmodell kann eine SQL-Abfrage aus einer Frage in Alltagssprache erzeugen, wenn es das Tabellenschema kennt. Gib ihm die Spaltennamen, Datentypen und Beziehungen, sonst erfindet es Namen. Das Ergebnis ist eine Hypothese, die du prüfen musst. Eine schlechte Abfrage liefert oft ein plausibles Ergebnis, das falsch ist.

Beispiel: Abfrage mit vollständigem Schema

```
Tabelle verkauf: bestell_id, datum, region, produkt,
menge, einzelpreis, storno, umsatz. Tabelle regionen:
region, gebiet_leitung. Schreibe eine SQL-Abfrage, die den
Umsatz je gebiet_leitung für stornofreie Bestellungen
summiert. Verbinde die Tabellen über region. Nenne danach
die Stelle, an der ein doppelter Eintrag in regionen das
Ergebnis verfälschen würde.
```

5.5 Abfragen überprüfen und optimieren

Jede Abfrage gehört an einer unabhängigen Rechnung geprüft. Die einfachste Prüfung ist eine Summe ohne JOIN, denn sie darf nur die Gesamtsumme ergeben. Stimmt die Summe mit JOIN nicht überein, liegt ein Fehler in der Verbindung vor. Die Prüfung ist so wichtig, dass sie zum festen Teil jeder Auswertung gehört.

Optimierung bedeutet bei kleinen Datenmengen wenig. Wichtig ist Lesbarkeit: Abfragen, die man nicht versteht, lassen sich nicht prüfen. Bei großen Tabellen helfen Indizes und das Vermeiden unnötiger Verbindungen, die Details hängen vom Datenbanksystem ab.

Codebeispiel 5.1: Abfragen und Prüfung eines Doppeleintrags

```
import sqlite3

import pandas as pd

df = pd.read_csv("verkauf_bereinigt.csv", sep=";")
df = df[~df["storno"]]
reg = pd.read_csv("regionen.csv", sep=";")

db = sqlite3.connect(":memory:")
df.to_sql("verkauf", db, index=False)
reg.to_sql("regionen", db, index=False)


def abfrage(sql):
    return pd.read_sql(sql, db).to_string(index=False)


# Umsatz je Region
print(abfrage("""
    SELECT region, ROUND(SUM(umsatz), 2) AS umsatz
    FROM verkauf
    GROUP BY region
    ORDER BY umsatz DESC
"""))

# Verknuepfung mit der Leitungsliste
print(abfrage("""
    SELECT r.region, r.gebiet_leitung,
           ROUND(SUM(v.umsatz), 2) AS umsatz
    FROM verkauf v
    JOIN regionen r ON v.region = r.region
    GROUP BY r.region, r.gebiet_leitung
    ORDER BY r.region
"""))

# Fehlerfall: die Regionenliste enthaelt Nord zweimal
db.execute("INSERT INTO regionen VALUES ('Nord', 'Neu')")
print("--- nach doppeltem Eintrag ---")
print(abfrage("""
    SELECT ROUND(SUM(v.umsatz), 2) AS umsatz_mit_join
    FROM verkauf v
    JOIN regionen r ON v.region = r.region
"""))
print(abfrage("""
    SELECT ROUND(SUM(umsatz), 2) AS umsatz_ohne_join
    FROM verkauf
"""))
```

Ausgabe

```
 region  umsatz
   West 44530.9
    Süd 43408.0
    Ost 43297.8
   Nord 36652.8
 region gebiet_leitung  umsatz
   Nord         Müller 36652.8
    Ost         Wagner 43297.8
    Süd        Schmidt 43408.0
   West         Becker 44530.9
--- nach doppeltem Eintrag ---
  umsatz_mit_join
         204542.3
  umsatz_ohne_join
          167889.5
```

Das Skript lädt die bereinigten Daten in eine SQLite-Datenbank im Arbeitsspeicher. Die ersten beiden Abfragen liefern die Umsätze je Region und je Gebietsleitung. Danach wird ein doppelter Eintrag für die Region Nord in die Liste der Regionen eingefügt. Die Summe mit JOIN ist danach mehr als 36.000 Euro höher als die Summe ohne JOIN. Genau dieser Unterschied macht den Fehler sichtbar. Die Summe ohne JOIN ist die Kontrollgröße.

> **Achtung: Abfragen auf Produktivdaten**
>
> Eine Abfrage kann Daten verändern, wenn sie als UPDATE oder DELETE formuliert ist. Lass Modelle nur lesende Abfragen gegen eine Kopie ausführen, und prüfe jede Abfrage, bevor du sie auf eine echte Datenbank anwendest.

Typische Fehler

Der häufigste Fehler ist ein JOIN gegen eine Tabelle mit doppelten Schlüsseln, der Summen aufbläht. Ein zweiter ist ein fehlender GROUP-BY-Eintrag. Ein dritter ist, Spaltennamen zu verwenden, die es im Schema nicht gibt, weil das Modell sie erfunden hat.

Kurz gesagt

SQL beschreibt Daten präzise, und KI kann die Abfrage schreiben, wenn sie das Schema kennt. Die Prüfung gegen eine Summe ohne Verbindung ist die wichtigste Kontrolle.

Übungen

Übung 5.1: Schreibe eine Abfrage, die die Anzahl der Bestellungen je Produkt ausgibt, und prüfe die Summe gegen die Gesamtzahl der Zeilen.

Übung 5.2: Entferne den doppelten Eintrag im Skript wieder und zeige, dass die Summe mit JOIN dann mit der Kontrollsumme übereinstimmt.

Kapitel 6: Datenvisualisierung

6.1 Diagrammtypen

Ein Diagramm ist eine Antwort auf eine Frage. Ein Liniendiagramm zeigt Entwicklungen über die Zeit, ein Balkendiagramm vergleicht Gruppen, ein Streudiagramm zeigt den Zusammenhang zweier Zahlen. Ein Kreisdiagramm eignet sich für wenige Anteile an einem Ganzen, bei mehr als vier oder fünf Teilen wird es unlesbar. Die Wahl des Typs folgt aus der Frage, nicht aus dem Geschmack.

6.2 Gestaltung und Lesbarkeit

Ein gutes Diagramm verlangt wenig Entschlüsselung. Titel sagen, was zu sehen ist. Achsen beginnen bei Balkendiagrammen bei null, weil sonst Unterschiede übertrieben erscheinen. Farben dienen der Unterscheidung und nicht der Dekoration. Die Quelle und der Zeitraum gehören ans Diagramm. Edward Tufte hat in seinen Büchern zu diesen Regeln viel beigetragen, vor allem zum Verhältnis von Informationsgehalt und Tinte.

6.3 Matplotlib

Matplotlib ist die klassische Bibliothek für Diagramme in Python. Sie erzeugt Grafiken als Bilddatei oder zeigt sie in einem Fenster. Das folgende Beispiel erstellt ein Liniendiagramm für die Monatsumsätze und ein Balkendiagramm für die Regionen nebeneinander und speichert das Ergebnis als PNG-Datei.

Codebeispiel 6.1: Liniendiagramm und Balkendiagramm

```
import matplotlib
matplotlib.use("Agg")
import matplotlib.pyplot as plt
import pandas as pd

df = pd.read_csv("verkauf_bereinigt.csv", sep=";")
df = df[~df["storno"]]

monat = df.groupby("monat")["umsatz"].sum()
region = df.groupby("region")["umsatz"].sum().sort_values()

fig, (links, rechts) = plt.subplots(1, 2, figsize=(9, 3.6),
                                    gridspec_kw={"width_ratios": [2, 1]})
links.plot(monat.index, monat.values, marker="o", color="#1F3A5F")
links.set_title("Umsatz je Monat (2025)", fontsize=10)
links.set_ylabel("Euro")
links.tick_params(axis="x", rotation=60, labelsize=7)
links.grid(alpha=0.3)

rechts.barh(region.index, region.values, color="#2A7F62")
rechts.set_title("Umsatz je Region", fontsize=10)
rechts.tick_params(labelsize=8)
rechts.grid(axis="x", alpha=0.3)

fig.tight_layout()
fig.savefig("umsatz_uebersicht.png", dpi=150)
print("Diagramm gespeichert")
```

Ausgabe

```
Diagramm gespeichert
```

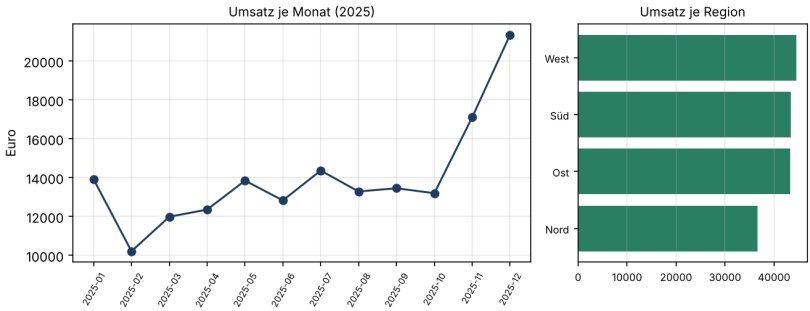


Abbildung 6.1: Monatsumsatz (links) und Umsatz je Region (rechts), erstellt mit dem Skript aus Codebeispiel 6.1

Die Abbildung zeigt die Saisonspitze im November und Dezember. Das Balkendiagramm wirkt auf den ersten Blick ausgewogen, aber der Unterschied zwischen den Regionen ist vergleichsweise klein. Die Achse im Balkendiagramm beginnt bei null, damit der Eindruck nicht übertrieben wird. Die Beschriftungen liegen im Diagramm selbst, sodass es ohne den Text verständlich bleibt.

6.4 Interaktive Visualisierungen

Interaktive Diagramme erlauben Zoom, Filter und Auswahl. Sie eignen sich für Auswertungen, die jemand selbst erkunden soll. Für einen Bericht, der gedruckt oder als Anhang verschickt wird, sind statische Diagramme meist verlässlicher, weil sie unabhängig von einem Programm angezeigt werden.

6.5 Dashboards

Ein Dashboard fasst mehrere Kennzahlen und Diagramme auf einer Seite zusammen. Es sollte nur die Kennzahlen zeigen, die für eine Entscheidung gebraucht werden. Ein Dashboard mit zwanzig Diagrammen wird selten gelesen. Lege Kennzahlen mit Zielwerten fest, damit jeder Wert eine Bewertung bekommt.

6.6 Daten verständlich präsentieren

Eine Zahl braucht Kontext, um zu wirken. Eine Umsatzsteigerung von zwei Prozent ist ohne Vergleichswert, Zeitraum und Schwankungsbreite kaum zu bewerten. Schreibe unter das Diagramm einen Satz, der die Aussage nennt, und einen zweiten, der die Grenzen nennt. Ein Modell kann Beschriftungen und Begleittexte vorschlagen, prüfe aber, ob sie die Zahlen korrekt wiedergeben.

Achtung: Diagramme können täuschen

Achsen, die nicht bei null beginnen, unterschiedliche Maßstäbe oder die Auswahl eines günstigen Zeitraums verändern den Eindruck. Prüfe jedes Diagramm, bevor du es weitergibst, und frage dich, ob ein anderer Ausschnitt eine andere Aussage nahelegen würde.

Typische Fehler

Der häufigste Fehler ist ein Diagrammtyp, der nicht zur Frage passt, etwa ein Kreisdiagramm für Entwicklungen über die Zeit. Ein zweiter ist eine fehlende Quellen- und Zeitraumangabe. Ein dritter ist ein Dashboard, das so viele Zahlen zeigt, dass keine davon auffällt.

Kurz gesagt

Der Diagrammtyp folgt der Frage. Achsen, Titel und Quellen machen ein Diagramm prüfbar, und ein Dashboard zeigt nur, was für eine Entscheidung nötig ist.

Übungen

Übung 6.1: Ändere das Skript so, dass das Balkendiagramm nach Umsatz sortiert ist, und beschreibe, welche Aussage dadurch deutlicher wird.

Übung 6.2: Erstelle für deine eigene Frage ein Diagramm und schreibe einen Satz, der die Aussage nennt, und einen, der die Grenze nennt.

Kapitel 7: KI-gestützte Interpretation

7.1 Trends erkennen

Ein Trend ist eine anhaltende Richtung in einer Zeitreihe. Er lässt sich mit einer Geraden beschreiben, die durch die Monatswerte gelegt wird. Die Steigung der Geraden zeigt, wie viel sich pro Monat im Durchschnitt ändert. Ein Modell kann helfen, den Trend zu benennen, die Rechnung dahinter sollte aber nachvollziehbar sein.

7.2 Auffälligkeiten erkennen

Auffälligkeiten sind Werte, die deutlich außerhalb des üblichen Bereichs liegen. Ein verbreitetes Verfahren ist das IQR-Kriterium. Es bestimmt die Mitte der Daten über das untere und das obere Quartil und markiert Werte, die mehr als das Anderthalbfache des Quartilsabstands außerhalb liegen. Das Verfahren geht auf den Statistiker John Tukey zurück und ist robust gegenüber einzelnen Extremwerten.

7.3 Kennzahlen interpretieren

Eine Kennzahl ist nur so gut wie ihre Definition. Umsatz kann Brutto oder Netto meinen, Storni können enthalten sein oder nicht. Schreibe die Definition in den Bericht und prüfe, ob sie für die Frage passt. Eine Kennzahl ohne Definition ist keine Kennzahl, sondern eine Behauptung.

7.4 Prognosen und Szenarien

Eine Prognose ist eine begründete Schätzung der Zukunft, keine Vorhersage. Das folgende Beispiel verwendet einen linearen Trend und zeigt eine grobe Spanne. Die Spanne beruht auf der Streuung der Abweichungen vom Trend. Das Modell berücksichtigt keine Saison, obwohl die Daten eine deutliche Spitze im November und Dezember zeigen. Die Prognose für die kommenden Monate ist deshalb nur eine Richtung und keine verlässliche Zahl.

7.5 Grenzen statistischer Aussagen

Statistische Aussagen gelten für die Daten, aus denen sie stammen. Ein Zusammenhang zwischen zwei Größen sagt nichts über Ursache und Wirkung aus. Zwei Größen können sich gemeinsam bewegen, weil sie von einer dritten abhängen, etwa der Saison. Eine kleine Stichprobe liefert unsichere Ergebnisse, und die Spanne der Unsicherheit wird oft zu schmal angegeben.

Codebeispiel 7.1: Trend, Prognose, Ausreißer und Korrelation

```
import numpy as np
import pandas as pd

df = pd.read_csv("verkauf_bereinigt.csv", sep=";")
df = df[~df["storno"]]

monat = df.groupby("monat")["umsatz"].sum()
x = np.arange(len(monat))
steigung, achse = np.polyfit(x, monat.values, 1)
print(f"Trend: {steigung:.0f} Euro pro Monat")

# Grobe Prognose mit linearem Trend, ohne Saisonmodell
rest = monat.values - (steigung * x + achse)
streuung = rest.std(ddof=2)
for schritt in range(1, 4):
    wert = steigung * (len(x) - 1 + schritt) + achse
    print(f"Prognose Monat +{schritt}: {wert:.0f} "
          f"(Spanne ca. +/- {1.96 * streuung:.0f})")

# Auffaellige Tage nach dem IQR-Verfahren
tage = df.groupby("datum")["umsatz"].sum()
q1, q3 = tage.quantile([0.25, 0.75])
grenze = 1.5 * (q3 - q1)
ausreisser = tage[(tage < q1 - grenze) | (tage > q3 + grenze)]
print("Auffaellige Tage:", len(ausreisser))

# Zusammenhang zwischen Bestellungen und Umsatz je Monat
bestellungen = df.groupby("monat")["bestell_id"].count()
r = np.corrcoef(bestellungen.values, monat.values)[0, 1]
print(f"Korrelation Bestellungen-Umsatz: {r:.2f}")
```

Ausgabe

```
Trend: 551 Euro pro Monat
Prognose Monat +1: 17572 (Spanne ca. +/- 4125)
Prognose Monat +2: 18123 (Spanne ca. +/- 4125)
Prognose Monat +3: 18674 (Spanne ca. +/- 4125)
Auffaellige Tage: 6
Korrelation Bestellungen-Umsatz: 0.12
```

Die Ausgabe zeigt einen Trend von etwa 551 Euro Umsatz pro Monat. Die Prognose für die drei folgenden Monate liegt zwischen rund 17.600 und 18.700 Euro und damit deutlich unter dem Dezemberwert von 21.346 Euro. Der lineare Trend glättet die Saisonspitze und erreicht sie nicht. Die Spanne von etwa 4.125 Euro ist groß im Verhältnis zu den einzelnen Monatswerten, weil nur zwölf Monate

vorliegen und die Saison nicht berücksichtigt ist. Sechs Tage gelten nach dem IQR-Kriterium als auffällig. Die Korrelation zwischen Bestellanzahl und Umsatz je Monat ist mit 0,12 schwach. Ein hoher Wert wäre aber auch nicht automatisch eine Ursache.

Achtung: Prognosen nicht als Zusage verwenden

Eine Prognose, die in einer Präsentation als Zielwert erscheint, wird schnell zur Verpflichtung. Nenne immer Methode, Zeitraum und Unsicherheit, und mache deutlich, dass sich die Annahmen ändern können.

7.6 Ein Ergebnis kritisch bewerten

Lass ein Modell eine Interpretation schreiben, und prüfe sie danach mit drei Fragen. Stimmt jede Zahl mit der Rechnung überein? Ist eine Ursache behauptet, die sich aus den Daten nicht ergibt? Fehlt eine Unsicherheitsangabe, die nötig wäre? Eine Interpretation, die alle drei Fragen besteht, ist brauchbar. Jede andere muss überarbeitet werden.

Schritt für Schritt: Eine KI-Interpretation prüfen

1. Lies die Interpretation und markiere jede Zahl und jede Ursache-Wirkungs-Aussage.
2. Vergleiche jede Zahl mit der Ausgabe der Berechnung.
3. Prüfe jede Ursache-Wirkungs-Aussage, ob sie sich aus den Daten allein begründen lässt.
4. Ergänze die fehlende Unsicherheit und die Definition der Kennzahl.
5. Speichere die geprüfte Fassung und vermerke, welche Angaben nachträglich verändert wurden.

Erwartetes Ergebnis: Eine Interpretation, deren Zahlen belegt, deren Ursachen begründet und deren Unsicherheit benannt ist.

Typische Fehler

Der häufigste Fehler ist, Korrelation als Ursache zu lesen. Ein zweiter ist, eine Prognose ohne Spanne zu präsentieren. Ein dritter ist, Ausreißer als Fehler zu behandeln, ohne nachzufragen, ob sie echte Ereignisse abbilden.

Kurz gesagt

Interpretation verbindet Zahlen mit Begründung. Trends, Auffälligkeiten und Prognosen sind Hinweise, deren Methode und Grenzen mit angegeben werden müssen.

Übungen

Übung 7.1: Ändere die Berechnung des Ausreißer-Kriteriums auf 3 Quartilsabstände und vergleiche die Anzahl der Tage.

Übung 7.2: Schreibe einen Satz über den Trend, der ohne Ursache-Wirkungs-Aussage auskommt, und einen zweiten, der die Unsicherheit benennt.

Kapitel 8: Praxisprojekte

8.1 Hinweise zu den Projekten

Die drei Projekte bauen auf den Kapiteln 1 bis 7 auf. Sie verwenden den Beispieldatensatz, können aber auch mit einer eigenen Tabelle durchgeführt werden. Jedes Projekt ist so beschrieben, dass du es mit Python, Pandas und einem Texteditor ausführen kannst. Ein Projekt gilt als abgeschlossen, wenn das erwartete Ergebnis vorliegt und jede Entscheidung in der Aufbereitung dokumentiert ist.

8.2 Projekt 1: Verkaufsdaten analysieren

Voraussetzungen und Werkzeuge

1. Python 3 mit den Bibliotheken Pandas, NumPy und Matplotlib.
2. Die Beispieldateien verkauf.csv und regionen.csv aus dem Archiv.
3. Ein Ordner für die Ausgaben, getrennt von den Rohdaten.

Hinweis: Die Analyse liefert eine Auswertung, eine Grafik und ein Protokoll der Aufbereitung.

Durchführung in fünf Schritten

1. Formuliere drei Fragen an die Daten, etwa zu Regionen, Produkten und Saison.
2. Führe die Qualitätsprüfung aus und dokumentiere jeden Befund mit seiner Anzahl.
3. Bereite die Daten auf und notiere jede Entscheidung mit Begründung.
4. Beantworte die drei Fragen mit Pivot-Tabelle, Abfrage oder Statistik, und prüfe jede Antwort mit einer unabhängigen Rechnung.
5. Erstelle eine Grafik zu einer der Fragen und schreibe je einen Satz zur Aussage und zur Grenze.

Erwartetes Ergebnis: Ein Bericht mit drei beantworteten Fragen, geprüften Zahlen, einer Grafik und einem Protokoll der Aufbereitung.

Fehlerbehebung: Stimmen die Summen nicht überein, prüfe zuerst Stornos und Dubletten. Erscheint ein Ausreißer, prüfe die Originalzeile, bevor du ihn behandelst. Sicherheitshinweis: Die Beispieldaten sind fiktiv. Mit echten Verkaufsdaten gelten Datenschutzregeln, sobald Personen erkennbar sind.

8.3 Projekt 2: Datenqualitätsbericht für eine eigene Tabelle

Dieses Projekt überträgt die Qualitätsprüfung auf eine Tabelle aus deinem Arbeitsumfeld. Du lernst dabei, welche Befunde typisch sind und welche Entscheidungen zu ihnen gehören. Wähle eine Tabelle, die keine sensiblen Daten enthält, oder entferne diese vorher.

Durchführung in fünf Schritten

1. Beschreibe die Tabelle, ihre Herkunft und den Zweck der Auswertung in einem Absatz.
2. Übertrage das Skript aus Codebeispiel 1.1 und passe die Spaltennamen an.
3. Führe die Prüfung aus und ordne jeden Befund einer Kategorie zu: Vollständigkeit, Eindeutigkeit, Gültigkeit oder Einheitlichkeit.
4. Entscheide für jeden Befund, ob er behoben, markiert oder ausgeschlossen wird, und begründe die Entscheidung.
5. Schreibe einen Bericht von höchstens zwei Seiten mit Befunden, Entscheidungen und offenen Fragen.

Erwartetes Ergebnis: Ein Qualitätsbericht, der jede Entscheidung nachvollziehbar macht und offene Fragen klar benennt.

Fehlerbehebung: Werden zu viele Befunde gemeldet, ist die Prüfregel zu streng. Werden keine gemeldet, prüfe, ob die Datei richtig eingelesen wurde. Sicherheitshinweis: Der Bericht enthält Auszüge aus den Daten. Entferne personenbezogene Angaben, bevor du ihn

weitergibst.

8.4 Projekt 3: Monatsbericht mit Prüfung

Im dritten Projekt erstellst du einen Monatsbericht, dessen Zahlen per Skript berechnet werden und dessen Text mit einem Sprachmodell entworfen wird. Der Bericht ist nur dann brauchbar, wenn jede Zahl im Text mit der Berechnung übereinstimmt. Diese Prüfung ist der Kern des Projekts.

Durchführung in fünf Schritten

1. Lege die Kennzahlen des Berichts mit Definition fest, etwa Gesamtumsatz, Anzahl Bestellungen und Stornoquote.
2. Berechne die Kennzahlen per Skript und speichere sie in einer Datei.
3. Lass ein Sprachmodell einen Berichtsentwurf aus dieser Datei schreiben und gib ihm die Kennzahlen als einzige Zahlenquelle vor.
4. Vergleiche jede Zahl im Entwurf mit der Datei und korrigiere Abweichungen.
5. Vermerke im Bericht die Definitionen, den Zeitraum und die Aufbereitungsschritte.

Erwartetes Ergebnis: Ein Monatsbericht, dessen Zahlen maschinell berechnet und an der Datei geprüft sind und dessen Definitionen im Text stehen.

Fehlerbehebung: Taucht im Entwurf eine Zahl auf, die in der Datei fehlt, ist sie erfunden. Entferne sie und verschärfe die Anweisung, nur die vorgegebenen Zahlen zu verwenden. Sicherheitshinweis: Berichte mit Umsatzzahlen gehören in den internen Bereich, wenn die Daten vertraulich sind.

Kurz gesagt

Die drei Projekte zeigen, dass Datenanalyse mit KI vor allem Prüfarbeit ist. Die Auswertung ist schnell, die Entscheidung über Aufbereitung, Zahlen und Aussagen bleibt verantwortlich bei dir.

Übungen

Übung 8.1: Führe Projekt 1 durch und notiere, welche Frage die aufwendigste Prüfung verlangt hat.

Übung 8.2: Ändere in Projekt 3 eine Kennzahl absichtlich in der Datei und prüfe, ob der Entwurf die Abweichung übernimmt.

Musterlösungen

Die folgenden Lösungen sind Vorschläge. Bei den Übungen gibt es keine einzig richtige Antwort, entscheidend ist die Begründung und die Prüfung am eigenen Material.

Kapitel 1

Lösung 1.1: Typische Befunde in den ersten fünfzig Zeilen sind unterschiedliche Schreibweisen bei Regionen und Produkten sowie eine Zeile mit anderem Datumsformat. Die Prüfung von Hand findet nicht alles, deshalb folgt das Skript.

Lösung 1.2: Für eine typische Quelle wie ein Kundenformular ergeben sich Dubletten bei Mehrfacheingaben, unterschiedliche Schreibweisen von Namen und Orten sowie fehlende Pflichtangaben.

Kapitel 2

Lösung 2.1: Mit dem falschen Trennzeichen liest Pandas die Datei als eine einzige Spalte ein. Mit dem richtigen Trennzeichen erscheinen sechs Spalten.

Lösung 2.2: Für eine Analyse der Umsätze braucht man Datum, Region und Umsatz. Namen, Adressen und Kontaktdaten sind vor der Weitergabe zu entfernen.

Kapitel 3

Lösung 3.1: Die Stichprobe ergibt eine Zahl, die der Formel entsprechen muss. Stimmt sie nicht, prüfe den Bereich und die Bedingung.

Lösung 3.2: Zuerst wird die Gesamtsumme geprüft, weil sie die Kontrollgröße für alle Zeilen und Spalten ist. Danach folgen die

Einzelzellen.

Kapitel 4

Lösung 4.1: Ohne Storno ergibt sich 167.889,50 Euro. Gerundet entspricht das dem Summenwert der Pivot-Tabelle aus Kapitel 3.

Lösung 4.2: Die Prüfung gibt Produkte ohne Preis aus. Ist die Liste leer, sind alle Preise vorhanden und die Annahme der Ergänzung entfällt.

Kapitel 5

Lösung 5.1: Die Summe der Anzahlen je Produkt muss der Zahl der Zeilen entsprechen, wenn keine Zeile mehrfach zählt.

Lösung 5.2: Ohne doppelten Eintrag stimmt die Summe mit JOIN mit der Kontrollsumme überein. Die Abweichung ist damit der Befund für den Fehler.

Kapitel 6

Lösung 6.1: Sortiert nach Umsatz wird die Rangfolge sofort sichtbar. Der Unterschied zwischen den Regionen wirkt dann deutlicher, obwohl die Daten dieselben bleiben.

Lösung 6.2: Ein guter Satz nennt Aussage, Zeitraum und Quelle. Ein Satz zur Grenze nennt Stichprobengröße, Saison oder fehlende Vergleichswerte.

Kapitel 7

Lösung 7.1: Mit drei Quartilsabständen werden weniger Tage markiert. Die Zahl sinkt, weil nur deutlichere Abweichungen erfasst werden.

Lösung 7.2: Ein Satz ohne Ursache lautet etwa: Der Umsatz steigt im Durchschnitt um rund 550 Euro pro Monat. Die Schätzung beruht auf zwölf Monaten.

Kapitel 8

Lösung 8.1: Die aufwendigste Prüfung betrifft meist die Frage nach Umsätzen, weil Stornos und Dubletten die Summe verfälschen können.

Lösung 8.2: Ein Entwurf übernimmt eine veränderte Zahl nur dann, wenn er sie nicht an der Datei prüft. Der Vergleich deckt die Abweichung auf.

Anhang: Checkliste für eine Datenanalyse

Gehe diese Checkliste durch, bevor du einem Analyseergebnis eine Entscheidung oder einem Bericht eine Zahl entnimmst.

- Frage: Ist die Frage in einem Satz formuliert?
- Quelle: Ist klar, woher die Daten stammen und in welchem Stand sie sind?
- Dubletten: Wurden vollständige und fachliche Dubletten geprüft?
- Fehlende Werte: Ist jede Ergänzung dokumentiert und begründet?
- Formate: Stimmen Datums-, Zahlen- und Textformate?
- Definitionen: Ist jede Kennzahl mit ihrer Definition beschrieben?
- Gegenrechnung: Wurde mindestens eine Zahl unabhängig nachgerechnet?
- Diagramm: Stimmen Achsen, Titel, Quelle und Zeitraum?
- Ursache: Wird keine Ursache behauptet, die sich aus den Daten nicht ergibt?
- Unsicherheit: Werden Schwankungsbreite und Grenzen genannt?

Glossar

Ausreißer: Wert, der deutlich außerhalb des üblichen Bereichs liegt. Ob er ein Fehler oder ein echtes Ereignis ist, muss geprüft werden.

CSV: Textdatei mit Zeilen als Datensätzen und einem Trennzeichen zwischen den Feldern.

Dublette: Mehrfach vorkommender Datensatz, vollständig oder nur in einem Schlüsselfeld.

DataFrame: Tabellenstruktur in Pandas mit benannten Spalten und Zeilen.

Datenqualität: Grad, zu dem ein Datensatz für eine Frage vollständig, eindeutig, gültig und einheitlich ist.

IQR: Interquartilsabstand, die Differenz zwischen oberem und unterem Quartil. Grundlage für das Ausreißerkriterium.

JOIN: Verbindung zweier Tabellen über eine gemeinsame Spalte in SQL.

Korrelation: Maß für einen gemeinsamen Verlauf zweier Größen. Sie zeigt keine Ursache an.

Kausalität: Ursache-Wirkungs-Beziehung zwischen zwei Größen, die sich nicht allein aus Korrelation ergibt.

Pivot-Tabelle: Zusammenfassung von Daten nach Zeilen- und Spaltenmerkmalen mit einer Rechenfunktion.

Prognose: Begründete Schätzung künftiger Werte auf Grundlage eines Modells und seiner Annahmen.

Quartil: Wert, unter dem ein Viertel der Daten liegt. Das untere und obere Quartil begrenzen die Mitte der Daten.

Regression: Anpassung einer Funktion an Datenpunkte, im einfachsten Fall einer Geraden.

Storno: Rückbuchung oder Stornierung einer Bestellung, meist mit negativer Menge oder negativem Betrag.

Zeitreihe: Werte, die in fester zeitlicher Reihenfolge erhoben wurden.

Quellenverzeichnis

Die folgenden Quellen bilden die Grundlage für die rechtlichen und methodischen Angaben dieses Bandes. Bei Gesetzen gilt stets die aktuell geltende Fassung.

Codd, Edgar F.: A Relational Model of Data for Large Shared Data Banks. In: Communications of the ACM, Band 13, Heft 6, 1970.

Tukey, John W.: Exploratory Data Analysis. Reading, Massachusetts: Addison-Wesley, 1977.

Tufte, Edward R.: The Visual Display of Quantitative Information. Cheshire, Connecticut: Graphics Press, 1983.

McKinney, Wes: Python for Data Analysis. Sebastopol: O'Reilly Media, Auflage 3, 2022.

Dokumentation der Projekte Pandas, NumPy und Matplotlib sowie der Python-Standardbibliothek zu sqlite3. Stand bei jeder Nutzung prüfen.

Gesetz über Urheberrecht und verwandte Schutzrechte und Datenschutz-Grundverordnung, Verordnung (EU) 2016/679, Artikel 5 zu den Grundsätzen der Verarbeitung. Maßgeblich ist die aktuell gültige Fassung.

Stichwortverzeichnis

Eine Auswahl wichtiger Begriffe mit Verweisen auf die Kapitel. Die Angaben beziehen sich auf die Kapitelnummern dieses Bandes.

Begriff	Kapitel
Ausreißer	6, 7
Dublette	1, 2, 4, 5
Datenqualität	1
Diagramm	6
Formel	3
GROUP BY	5
IQR	7
JOIN	5
Korrelation	7
Pivot-Tabelle	3
Prognose	7
Storno	1, 3, 4
Trend	7
Zeitreihe	1, 7

KI PRAXIS

Band 5 zeigt, wie du Daten prüfst, aufbereitest, auswertest und darstellst, ohne den Ergebnissen blind zu vertrauen. Du lernst, Formeln und Abfragen einer KI zu prüfen, und du erkennst Trends und Auffälligkeiten mit Angabe ihrer Grenzen.

Alle Codebeispiele sind mit Pandas 3.0 ausgeführt und mit ihren Ausgaben abgedruckt. Der Beispieldatensatz enthält absichtlich typische Fehler, die du finden sollst.

Die weiteren Bände der Reihe KI PRAXIS: Band 1 KI im produktiven Alltag, Band 2 Recherche und Wissensmanagement, Band 3 Automatisierung und KI-Agenten, Band 4 lokale KI und eigene KI-Systeme, Band 6 Dokumente, Präsentationen und Fachbücher, Band 7 Lernen mit KI und Band 8 Sicherheit und verantwortungsvolle Nutzung.

Eugen Becker | 1. Auflage, November 2026